

SFG-XIDS: Mạng tương tác cộng tính theo nhóm đặc trưng ngữ nghĩa với cơ chế giải thích phân cấp chính xác cho phát hiện xâm nhập mạng

A Semantic Feature-Group Additive Interaction Network with Extract Hierarchical Explanations for Network Intrusion Detection

1. Tóm tắt

Các hệ thống phát hiện xâm nhập mạng (IDS) dùng học máy hiện nay đạt độ chính xác cao trên các bộ dữ liệu chuẩn. Vấn đề là khi mô hình báo động, chuyên viên an ninh khó biết vì sao. Các công cụ giải thích phổ biến như SHAP trả về điểm của từng đặc trưng, tức là một danh sách 40–80 con số. Trong khi đó, chuyên viên thường suy nghĩ theo nhóm thông tin: thông tin cơ bản của kết nối, nội dung, thời gian, lịch sử kết nối.

Đề tài đề xuất **SFG-XIDS**, một mạng nơ-ron phát hiện xâm nhập được thiết kế để tự giải thích theo nhóm. Ý tưởng chính: logit của mỗi lớp được tính bằng **tổng các thành phần**, mỗi thành phần chỉ phụ thuộc vào một nhóm đặc trưng hoặc một cặp nhóm. Các nhóm lấy đúng theo cách chia của tác giả hai bộ dữ liệu UNSW-NB15 và NSL-KDD. Nhờ cấu trúc này, mô hình cho lời giải thích 2 cấp:

- **Cấp nhóm:** đóng góp của mỗi nhóm được tính bằng công thức trực tiếp và đúng bằng giá trị Shapley của nhóm, không phải ước lượng.
- **Cấp đặc trưng:** đóng góp của từng đặc trưng trong nhóm, tính bằng Expected Gradients, có tổng bằng đúng đóng góp của nhóm.

Kết quả chính (bộ chia train/test chính thức, 5 seed):

- **Độ chính xác ngang các mô hình mạnh.** Macro-F1 10 lớp trên UNSW-NB15 là 52,35% (LightGBM 52,68%, XGBoost 51,43%, FT-Transformer 48,86%); trên NSL-KDD 5 lớp là 62,88%. Với bài toán nhị phân (tấn công/bình thường), các mô hình trên UNSW-NB15 chênh nhau khoảng 2 điểm macro-F1; trên NSL-KDD, XGBoost tốt nhất (81,16%) và SFG-XIDS đạt 78,98%.
- **Lời giải thích đúng như thiết kế.** Đóng góp nhóm khớp với giá trị Shapley tính theo định nghĩa, sai số lớn nhất $1,9 \times 10^{-6}$. Tổng đóng góp các đặc trưng khớp với đóng góp nhóm, sai số trung vị 0,1%.
- **Hai cách làm tắt phổ biến cho kết quả sai.** Nếu tính EG cho từng đặc trưng trên toàn mô hình rồi cộng theo nhóm, nhóm quan trọng nhất bị đổi ở 9-15% số luồng. Trọng số attention của mô hình nhiều nhánh chỉ khớp yếu với giá trị Shapley của chính mô hình đó (Kendall $\tau = 0,29$ trên UNSW-NB15 và 0,49 trên NSL-KDD).

- **Lời giải thích hợp lý.** Trên NSL-KDD, đóng góp nhóm khớp với mục đích thiết kế của bộ đặc trưng (nhóm nội dung dùng để bắt R2L/U2R, nhóm lưu lượng dùng để bắt DoS/Probe) ở cả 5 seed.
- **Hạn chế chính:** lời giải thích thay đổi giữa các lần train nhiều hơn so với XGBoost.

Từ khóa: phát hiện xâm nhập mạng; AI giải thích được; nhóm đặc trưng; giá trị Shapley; mô hình cộng tính; Expected Gradients.

2. Đặt vấn đề

2.1. Bối cảnh

IDS dùng học máy phân loại mỗi luồng mạng là bình thường hay thuộc một loại tấn công. Trên các bộ dữ liệu chuẩn như UNSW-NB15 và NSL-KDD, mô hình cây tăng cường (XGBoost, LightGBM) và mạng nơ-ron đều đạt độ chính xác cao. Nhưng trong trung tâm điều hành an ninh (SOC), mỗi cảnh báo đều phải có người xem xét và quyết định cách xử lý. Nếu không biết vì sao mô hình báo động, chuyên viên khó tin mô hình và khó phản ứng đúng.

2.2. Vấn đề của cách giải thích hiện nay

Giải thích theo từng đặc trưng quá vụn. Cách làm phổ biến là chạy SHAP hoặc LIME trên mô hình đã train. Kết quả là điểm của 40-80 đặc trưng. Nhiều đặc trưng tương quan hoặc trùng thông tin với nhau, nên chuyên viên phải tự gom chúng lại mới hiểu được hành vi của luồng.

Bộ dữ liệu vốn đã được thiết kế theo nhóm. Bộ đặc trưng KDD'99 (gốc của NSL-KDD) bắt nguồn từ các đặc trưng Lee và Stolfo xây dựng trên dữ liệu DARPA 1998, gồm 4 nhóm: cơ bản, nội dung, lưu lượng trong 2 giây gần nhất, và lưu lượng tới cùng máy đích trong 100 kết nối gần nhất. Nhóm nội dung dùng để bắt tấn công R2L/U2R, các nhóm lưu lượng dùng để bắt DoS/Probe. UNSW-NB15 cũng mô tả đặc trưng theo các nhóm: luồng, cơ bản, nội dung, thời gian và đặc trưng tạo thêm. Vì vậy, giải thích theo nhóm là cách tự nhiên và khớp với cách chuyên viên suy nghĩ.

Hai cách làm tắt phổ biến đều không đáng tin:

- Tính điểm cho từng đặc trưng trên toàn mô hình rồi cộng theo nhóm. Tổng này không phải giá trị Shapley của nhóm và có thể làm sai thứ tự nhóm quan trọng nhất.
- Dùng mô hình nhiều nhánh (mỗi nhóm một nhánh), kết hợp các nhánh bằng attention hoặc cổng (gating), rồi coi trọng số attention/cổng là mức quan trọng của nhóm. Sau khi các nhánh đã trộn với nhau qua attention và kết nối tắt (residual), trọng số này không nhất thiết phản ánh đúng đóng góp của nhóm vào kết quả.

Lời giải thích hiếm khi được kiểm tra bằng số liệu. Phần lớn nghiên cứu chỉ vẽ biểu đồ điểm SHAP. Các tiêu chí đánh giá phương pháp giải thích trong lĩnh vực bảo mật ít khi được áp dụng.

2.3. Câu hỏi nghiên cứu

- Có xây được mô hình IDS mà đóng góp của mỗi nhóm đặc trưng là một phần có thật trong mô hình, tính chính xác được, mà độ chính xác vẫn ngang các mô hình mạnh không?
- Có “mở” được mỗi nhóm xuống từng đặc trưng sao cho tổng đóng góp các đặc trưng trong nhóm đúng bằng đóng góp của nhóm không?
- Khi kiểm tra bằng số liệu, lời giải thích này có đúng, ổn định, hợp lý với kiến thức chuyên môn và tốt hơn hai cách làm tắt ở trên không?

2.4. Hướng tiếp cận

Thay vì train một mô hình black-box rồi giải thích sau khi train (post-hoc), đề tài thiết kế một mô hình tự giải thích được ở cấp nhóm. Mô hình vẫn có một encoder riêng cho từng nhóm như các mô hình nhiều nhánh, nhưng phần kết hợp ở cuối bị ràng buộc thành dạng cộng: $\text{logit} = \text{tổng các thành phần riêng của từng nhóm} + \text{tổng các thành phần tương tác của từng cặp nhóm}$. Nhờ vậy, đóng góp của nhóm là các thành phần có thật trong logit, giá trị Shapley của nhóm tính được bằng công thức trực tiếp và mỗi nhóm có thể mở xuống cấp đặc trưng mà các con số vẫn cộng khớp.

3. Những nghiên cứu liên quan

Phần này tóm tắt 3 công trình gần nhất với đề tài: (1) một bài cùng bài toán – IDS có nhóm đặc trưng và có giải thích; (2) một bài cùng ý tưởng giải thích theo nhóm từ mô hình cộng tính; (3) một bài là nền tảng lý thuyết cho cách tính đóng góp nhóm.

3.1. Explainable feature-group-aware cross-attentive expert fusion for IoMT intrusion detection (*)

Bài toán. Phát hiện xâm nhập nhiều lớp cho mạng thiết bị y tế kết nối Internet (IoMT), với yêu cầu mô hình phải giải thích được. Bài đăng trên Sensors 26(13), 4293, tháng 7/2026.

Cách làm. Các đặc trưng số được tự động chia thành 5 nhóm theo ý nghĩa: thời gian, giao thức, kích thước/tốc độ, thống kê và nhóm còn lại. Mỗi nhóm có một mạng “chuyên gia” riêng (2 lớp fully connected, LayerNorm, Dropout). Một mạng cổng (gate) nhìn vào toàn bộ vector đầu vào và tính trọng số cho từng chuyên gia: $g = \text{softmax}(\frac{W_g \hat{x} + b_g}{\tau})$. Bài thêm 2 số hạng điều chuẩn để các chuyên gia được dùng đều nhau và để cổng không chọn quá dứt khoát (giữ entropy). Biểu diễn trộn là tổng có trọng số của các chuyên gia. Song

song đó, biểu diễn của các chuyên gia đi qua self-attention giữa các chuyên gia (có residual, LayerNorm, rồi lấy trung bình). Hai biểu diễn được nối lại, đi qua các lớp fully connected và softmax.

Cách giải thích. SHAP và LIME cho từng đặc trưng (tính sau khi train); cộng SHAP theo nhóm để vẽ heatmap nhóm – lớp; xem trọng số cộng theo từng lớp; và một “điểm căn chỉnh” (alignment score) đo mức giống nhau giữa SHAP theo nhóm và trọng số cộng.

Dữ liệu và kết quả. CICIoMT2024 (6 lớp và 19 lớp, dùng bộ chia chính thức) và IoMT-TrafficData (9 lớp). Accuracy đạt 99,76% (MCC 0,9951) với 6 lớp, 99,07% (MCC 0,9892) với 19 lớp và 99,92% (MCC 0,9988) trên IoMT-TrafficData. Thí nghiệm ablation cho thấy mô hình đầy đủ là tốt nhất.

Điểm chưa đáp ứng mục tiêu của đề tài. Logit không cộng theo nhóm: công nhìn toàn bộ đặc trưng và self-attention trộn các chuyên gia với nhau. Vì vậy trọng số cộng không phải đóng góp của nhóm, và SHAP cộng theo nhóm không phải giá trị Shapley của nhóm. Bài không kiểm tra bằng số liệu xem lời giải thích có đúng, có trung thực với mô hình hay có ổn định không; “điểm căn chỉnh” chỉ so hai cách giải thích với nhau, không so với mô hình.

Liên hệ với SFG-XIDS. Cùng ý tưởng mỗi nhóm đặc trưng một mạng riêng. Khác biệt: SFG-XIDS thay phần trộn (cộng, attention) bằng lớp output cộng theo nhóm GAI-Head, để đóng góp nhóm là thành phần có thật và tính chính xác được. Biến thể SFG-Attn trong đề tài dựng lại kiểu kết hợp bằng attention và trọng số pooling để kiểm tra trực tiếp xem các trọng số đó có phản ánh đúng đóng góp không (mục 8.5).

3.2. The most important features in generalized additive models might be groups of features ()**

Bài toán. Khi các đặc trưng tương quan với nhau, tín hiệu chung của cả nhóm có thể rất quan trọng cho dự đoán, trong khi từng đặc trưng riêng lẻ lại có điểm quan trọng thấp. Vấn đề càng rõ khi dữ liệu có sẵn các nhóm tự nhiên, như dữ liệu nhiều nguồn (multimodal). Bài đăng trên Scientific Reports 16, 14371 (21/3/2026); nhóm tác giả có Rich Caruana, đồng tác giả của GA²M và EBM.

Cách làm. Bài dùng Explainable Boosting Machine (EBM), một mô hình cộng tính có thêm các số hạng tương tác giữa từng cặp đặc trưng:

$$g(\mathbb{E}[y]) = \beta_0 + f_1(x_1) + \cdots + f_n(x_n) + \sum_{i \neq j} f_{i,j}(x_i, x_j)$$

Mỗi f_i là một hàm riêng của đặc trưng x_i (shape function), mỗi $f_{i,j}$ là hàm tương tác của cặp (x_i, x_j) . Khi train, EBM tách rõ để phân riêng của một đặc trưng không bị chuyển sang các số hạng tương tác và ngược lại (purification); các hàm đều có trung bình bằng 0. Với mỗi mẫu t trong tập train T , ký hiệu t_j là giá trị của đặc trưng j . Độ quan trọng của một đặc trưng là trung bình trị tuyệt đối hàm riêng của nó:

$$I_{x_j} = \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} |f_j(t_j)|$$

Bài mở rộng cách tính này cho nhóm. Một nhóm G gồm k đặc trưng và có thể thêm một số cặp tương tác:

$$G = \{x_{i_1}, \dots, x_{i_k}, (x_{\ell_1}, x_{\ell_2}), \dots, (x_{\ell_{k'}-1}, x_{\ell_{k'}})\}$$

Độ quan trọng của nhóm là trung bình trên tập train của trị tuyệt đối tổng các hàm thuộc nhóm:

$$I_G := \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} |f_{i_1}(t_{i_1}) + \dots + f_{i_k}(t_{i_k}) + f_{\ell_1, \ell_2}(t_{\ell_1}, t_{\ell_2}) + \dots + f_{\ell_{k'}-1, \ell_{k'}}(t_{\ell_{k'}-1}, t_{\ell_{k'}})|$$

Điểm mấu chốt: trị tuyệt đối được lấy sau khi cộng các hàm trong nhóm. Đóng góp cùng chiều thì cộng dồn, đóng góp ngược chiều thì triệt tiêu nhau. Vì vậy độ quan trọng của nhóm nói chung không bằng tổng độ quan trọng riêng: bài chỉ ra $0 \leq I_G \leq \text{tổng độ quan trọng của các đặc trưng trong nhóm}$, và nhóm chỉ có một đặc trưng thì có độ quan trọng đúng bằng đặc trưng đó. Nhóm được định nghĩa sau khi train, có thể chồng lên nhau, không cần train lại mô hình và mỗi mẫu chỉ cần tính k hàm nên chi phí là $O(k|T|)$. Bài chỉ xét độ quan trọng toàn cục (một con số cho cả tập dữ liệu) và so sánh với: cộng độ quan trọng của từng đặc trưng, groupSHAP và grouped permutation importance (GPI).

Kết quả. Ba thí nghiệm mô phỏng với 2 đặc trưng x và z :

(1) z là bản sao của x , tín hiệu cùng chiều – độ quan trọng của nhóm bằng tổng độ quan trọng riêng (khoảng 2 lần mỗi đặc trưng);

(2) tín hiệu ngược chiều, x và z độc lập – độ quan trọng của nhóm lớn hơn từng đặc trưng nhưng nhỏ hơn tổng;

(3) tín hiệu ngược chiều, x và z tương quan cao – hai hàm gần như triệt tiêu nhau, độ quan trọng của nhóm còn nhỏ hơn cả từng đặc trưng. Về tốc độ, trên 7 bộ dữ liệu OpenML, cách tính này nhanh hơn GPI và groupSHAP khoảng 10 lần, trừ bộ GCM chỉ nhanh hơn không đáng kể.

Hai ứng dụng y tế:

(i) dữ liệu thần kinh NCANDA (1.396 lượt đo của 521 người 12–18 tuổi, 154 đặc trưng, 9 nhóm) để nhận diện một triệu chứng trầm cảm (negative valence), EBM đạt AUC 0,874. Nhóm “sự kiện trong đời và sang chấn” quan trọng nhất, dù xét riêng lẻ chỉ 5 đặc trưng của nhóm này nằm trong top 20; thứ hạng nhóm giống groupSHAP nhất.

(ii) Dữ liệu phẫu thuật thay khớp háng toàn phần ở Pennsylvania (105.336 bệnh nhân) để dự đoán tử vong trong 90 ngày (tỉ lệ 0,3%), EBM đạt AUC 0,76. Nhóm các yếu tố xã hội ở cấp cộng đồng (lấy theo mã bưu chính nơi ở, ví dụ tỉ lệ sống một mình, thu nhập hộ gia đình, tỉ lệ không có bảo hiểm, học vấn) quan trọng nhất, gấp khoảng 8 lần đặc trưng chủng tộc (race).

Điểm chưa đáp ứng mục tiêu của đề tài. Mô hình vẫn cộng ở cấp từng đặc trưng (EBM thường chỉ có tương tác giữa tối đa 2 đặc trưng), nên không học được tương tác phức tạp bên trong một nhóm. Nhóm được gom sau khi train và phải do người dùng định nghĩa trước; tương tác chỉ có giữa từng cặp đặc trưng, không có thành phần tương tác giữa các cặp nhóm. Độ quan trọng là con số cho cả tập dữ liệu, không phải đóng góp của nhóm cho từng mẫu, và không cộng khớp với độ quan trọng của từng đặc trưng (chỉ biết $I_G \leq$ tổng độ quan trọng riêng). Bài cũng không làm về phát hiện xâm nhập.

Liên hệ với SFG-XIDS. Cùng quan điểm “nhóm mới là đơn vị nên giải thích”. Khác biệt: SFG-XIDS đặt tính cộng ngay ở cấp nhóm (bên trong nhóm được tương tác tùy ý, giữa các nhóm tương tác theo từng cặp) và cho đóng góp của nhóm cho từng luồng, ở cả cấp nhóm lẫn cấp đặc trưng. Thước đo toàn cục của đề tài (tỉ lệ trung bình $|\phi_i|$ theo lớp, Bảng 13) có cùng tinh thần với I_G : lấy trị tuyệt đối sau khi đã cộng đóng góp bên trong nhóm.

3.3. Unifying local and global model explanations by functional decomposition of low dimensional structures (***)

Bài toán. Giá trị SHAP có thể gây hiểu nhầm khi các đặc trưng vừa tương quan vừa tương tác với nhau: tại một điểm, phần hiệu ứng riêng và phần tương tác có thể triệt tiêu nhau, làm một đặc trưng có tác động rõ ràng vẫn nhận SHAP bằng 0. Bài muốn thống nhất giải thích cho từng mẫu (SHAP) và giải thích toàn cục (partial dependence, PDP) trong cùng một cách tách hàm. Bài đăng tại AISTATS 2023 (PMLR 206, tr. 7040–7060).

Cách làm. Tách hàm dự đoán thành tổng: hằng số + hiệu ứng riêng của từng đặc trưng + các thành phần tương tác bậc cao, kèm một ràng buộc để cách tách là duy nhất. Với ràng buộc này, PDP của một đặc trưng đúng bằng hiệu ứng riêng của nó cộng hằng số. Còn SHAP (loại interventional) của đặc trưng k bằng tổng các thành phần có chứa k , mỗi thành

phần chia cho số đặc trưng tham gia – tức một tương tác giữa 2 đặc trưng được chia đôi cho mỗi bên. Các thành phần được tính chính xác cho XGBoost và random planted forest.

Kết quả. Từ một lần tách hàm đọc được cả giải thích cục bộ lẫn toàn cục. Thí nghiệm với XGBoost và random planted forest trên dữ liệu mô phỏng, Bike Sharing và Adult cho thấy cách tách này cho nhiều thông tin hơn SHAP và SHAP interaction, làm lộ các tương tác bậc cao. Cách tách còn giúp giảm thiên vị (bias) bằng cách bỏ mọi thành phần có chứa đặc trưng nhạy cảm và gợi ý một thước đo độ quan trọng mới. Công trình song song của Bordt và von Luxburg (*From Shapley values to generalized additive models and back*) đi đến kết quả tương tự theo hướng khác: mỗi cách định nghĩa SHAP (value function) ứng với đúng một cách tách hàm (gọi là Shapley-GAM, tính bằng biến đổi Möbius) và giá trị Shapley chia đều mỗi thành phần tương tác cho các biến tham gia.

Điểm chưa đáp ứng mục tiêu của đề tài. Chỉ tính chính xác được với mô hình có cấu trúc bậc thấp hoặc tổng của các cấu trúc như vậy (chủ yếu là mô hình cây). Bài làm ở cấp từng đặc trưng, không xét nhóm, không có bước mở nhóm xuống đặc trưng, và không làm về phát hiện xâm nhập.

Liên hệ với SFG-XIDS. Đây là nền tảng lý thuyết cho cách tính đóng góp nhóm: Tính chất 1 (ϕ_i = hiệu ứng riêng của nhóm + một nửa các phần tương tác với nhóm khác) là hệ quả của kết quả này khi áp dụng cho nhóm, với tập nền mà các nhóm được lấy độc lập với nhau. SFG-XIDS **thiết kế mô hình** để tương tác giữa các nhóm chỉ có bậc 2, nhờ vậy phép tính chính xác có công thức trực tiếp và rõ; đồng thời thêm cấp đặc trưng để mở từng nhóm mà tổng vẫn khớp.

So sánh tổng hợp. Bảng 1 đặt SFG-XIDS cạnh ba công trình trên.

Bảng 1: So sánh SFG-XIDS với ba công trình liên quan nhất

Tiêu chí	Khan và cs. (*)	Bosschieter và cs. (**)	Hiabu và cs. (***)	SFG-XIDS
Lĩnh vực	IDS cho IoMT	Y tế (thần kinh, chỉnh hình)	Phương pháp giải thích chung	IDS mạng
Dữ liệu	CICIoMT2024, IoMT-TrafficData	NCANDA, thay khớp háng, mô phỏng, OpenML	Mô phỏng, Bike Sharing, Adult	UNSW-NB15, NSL-KDD
Nhóm đặc trưng	5 nhóm, chia tự động	Nhóm theo chuyên môn, định nghĩa sau khi train	Không (từng đặc trưng)	4 nhóm theo cách chia gốc của bộ dữ liệu
Mô hình	Chuyên gia theo nhóm + cổng (MoE) + self-attention	EBM, cộng theo từng đặc trưng	XGBoost, random planted forest	Encoder theo nhóm + GAI-Head cộng theo nhóm

Giải thích cấp nhóm	SHAP cộng theo nhóm; trọng số công	Tổng các hàm trong nhóm (toàn cục)	Không có	Đóng góp nhóm cho từng luồng + bản đồ tương tác
Đóng góp nhóm chính xác?	Không	Không tính cho từng mẫu (chỉ toàn cục)	Chính xác, nhưng ở cấp đặc trưng	Có, đúng bằng giá trị Shapley của nhóm
Nhóm và đặc trưng cộng khớp?	Không	Không (độ quan trọng nhóm $\leq$ tổng độ quan trọng riêng)	Không áp dụng	Có (Tính chất 2)
Kiểm tra lời giải thích bằng số liệu	Chỉ đo mức giống nhau giữa hai cách giải thích	Mô phỏng để minh họa; so với groupSHAP, GPI trên dữ liệu thật	Minh họa trên mô phỏng và dữ liệu thật	Đúng, khớp 2 cấp, trung thực, ổn định, hợp lý

Tóm lại: Khan và cộng sự có nhóm đặc trưng trong IDS, nhưng lời giải thích nhóm không phải đóng góp chính xác của nhóm và chưa được kiểm tra bằng số liệu. Bosschieter và cộng sự giải thích theo nhóm từ mô hình cộng tính, nhưng mô hình cộng ở cấp đặc trưng, chỉ cho con số toàn cục và không thuộc lĩnh vực IDS. Hiabu và cộng sự cho cơ sở để tính Shapley chính xác từ việc tách hàm, nhưng ở cấp đặc trưng. Chưa có công trình nào làm đủ cả 4 điều:

- (i) mô hình cộng theo nhóm đặc trưng có ý nghĩa cho IDS;
- (ii) đóng góp nhóm chính xác cho từng luồng, kèm bản đồ tương tác;
- (iii) mở nhóm xuống đặc trưng mà tổng vẫn khớp;
- (iv) kiểm tra lời giải thích bằng số liệu. SFG-XIDS nhắm vào đúng chỗ trống này.

4. Mục tiêu đề tài

Xây dựng và đánh giá một mô hình IDS dựa trên mạng nơ-ron, có độ chính xác ngang các mô hình mạnh, đồng thời giải thích được theo 2 cấp (nhóm đặc trưng $\rightarrow$ đặc trưng). Lời giải thích phải chính xác theo cấu trúc mô hình và được kiểm tra bằng số liệu. Cụ thể:

- Chia đặc trưng của UNSW-NB15 và NSL-KDD thành 4 nhóm theo cách chia gốc của mỗi bộ dữ liệu; so sánh với cách chia ngẫu nhiên.
- Thiết kế SFG-XIDS: mỗi nhóm một encoder riêng (embedding PLR + MLP) và lớp output cộng theo nhóm có tương tác cặp (GAI-Head); train với group dropout.
- Xây dựng cách giải thích 2 cấp và chứng minh: (i) đóng góp nhóm tính bằng công thức trực tiếp đúng bằng giá trị Shapley của nhóm; (ii) tổng đóng góp EG của các đặc trưng trong nhóm bằng đóng góp của nhóm.
- So sánh khả năng phát hiện (nhiều lớp và nhị phân) với các mô hình đối chứng (7 mô hình cho bài toán nhiều lớp, 5 mô hình cho bài toán nhị phân) theo quy trình chặt chẽ: dùng bộ chia train/test chính thức, 5 seed, tập test chỉ dùng để đánh giá cuối cùng. Toàn bộ chạy được trên một GPU phổ thông (Colab T4).

- Kiểm tra lời giải thích theo 5 tiêu chí: đúng, khớp giữa 2 cấp, trung thực, ổn định, hợp lý; so sánh trực tiếp với trọng số attention và với EG thông thường.

5. Mô tả chi tiết bài toán

Mỗi mẫu dữ liệu là một luồng mạng, mô tả bằng vector đặc trưng $x = (x_{\text{num}}, x_{\text{cat}})$ gồm các đặc trưng số và các đặc trưng phân loại (categorical). Các đặc trưng được chia thành 4 nhóm $G_1, \dots, G_4$; x_i là phần của x thuộc nhóm G_i . Nhãn y là một trong C lớp. Bài toán gồm 2 phần:

- **Phát hiện:** học hàm $f: x \mapsto (\hat{y}, p(c | x))$, tức dự đoán nhãn và xác suất của từng lớp. Có 2 bài toán: nhiều lớp ($C = 10$ với UNSW-NB15, $C = 5$ với NSL-KDD) và nhị phân (Normal/Attack).
- **Giải thích:** với luồng x và lớp c cần giải thích, trả về (i) đóng góp của 4 nhóm $\phi(x) \in \mathbb{R}^4$, có tổng $\sum_i \phi_i(x) = z_c(x) - E[z_c]$, trong đó z_c là logit của lớp c sau khi trừ trung bình logit các lớp và $E[z_c]$ là giá trị trung bình trên tập nền; (ii) bản đồ tương tác giữa các cặp nhóm; (iii) đóng góp của từng đặc trưng $a(x) \in \mathbb{R}^d$, sao cho tổng trong mỗi nhóm bằng đóng góp của nhóm: $\sum_{k \in G_i} a_k(x) = \phi_i(x)$.

5.1. Dữ liệu đầu vào

Đề tài dùng 2 bộ dữ liệu công khai và giữ đúng bộ chia train/test chính thức do tác giả bộ dữ liệu công bố. Không trộn lại rồi chia lại, vì cách đó làm kết quả đẹp hơn thực tế.

Bảng 2: Thông tin hai bộ dữ liệu đầu vào

Thông tin	UNSW-NB15	NSL-KDD
Nguồn	UNSW-NB15: A comprehensive data set for network intrusion detection systems; UNSW_NB15_training-set.csv, UNSW_NB15_testing-set.csv	A detailed analysis of the KDD CUP 99 dataset; KDDTrain+.txt, KDDTest+.txt
Số dòng train / test	175.341 / 82.332	125.973 / 22.544
Số đặc trưng dùng	42 (39 số, 3 phân loại)	40 (37 số, 3 phân loại)
Đặc trưng phân loại	proto, service, state	protocol_type, service, flag
Cột bỏ đi	id; label, attack_cat (là nhãn)	num_outbound_cmds (luôn bằng 0), difficulty
Nhãn nhiều lớp	10 lớp (attack_cat)	5 lớp (Normal, DoS, Probe, R2L, U2R), gom từ 39 kiểu tấn công theo cách gom chuẩn

Nhân nhị phân	Attack nếu attack_cat $\neq$ Normal	Attack nếu nhãn 5 lớp $\neq$ Normal
Tập validation	Tách 10% tập train, giữ tỉ lệ các lớp, cố định	Như UNSW-NB15
Nhân nhị phân	Attack nếu attack_cat $\neq$ Normal	Attack nếu nhãn 5 lớp $\neq$ Normal
Tập validation	Tách 10% tập train, giữ tỉ lệ các lớp, cố định	Như UNSW-NB15

Bảng 3: Số dòng của mỗi lớp trong tập train và tập test

Lớp	Train	Test
UNSW-NB15		
Normal	56	37
Generic	40	18.871
Exploits	33.393	11.132
Fuzzers	18.184	6.062
DoS	12.264	4.089
Reconnaissance	10.491	3.496
Analysis	2	677
Backdoor	1.746	583
Shellcode	1.133	378
Worms	130	44
NSL-KDD		
Normal	67.343	9.711
DoS	45.927	7.458
Probe	11.656	2.421
R2L	995	2.887
U2R	52	67

Cả hai bộ dữ liệu mất cân bằng mạnh (ví dụ Worms chỉ có 130 dòng train, U2R chỉ có 52). Trong KDDTest+ có 17 kiểu tấn công không xuất hiện trong tập train (ví dụ apache2, mailbomb, mscan, snmpguess, httptunnel). Các dòng này vẫn được tính khi đo khả năng phát hiện, nhưng không đưa vào phân phân tích lỗi giải thích.

Bảng 4: Bốn nhóm đặc trưng theo cách chia gốc của bộ dữ liệu

Nhóm	UNSW-NB15	NSL-KDD
G1 – Basic	15: proto, service, state, dur, spkts, dpkts, sbytes, dbytes, rate, sttl, dttl, sload, dload, sloss, dloss	9: duration, protocol_type, service, flag, src_bytes, dst_bytes, land, wrong_fragment, urgent
G2 – Content	8: swin, dwin, stcpb, dtcpb, smean, dmean, trans_depth, response_body_len	12: hot, num_failed_logins, logged_in, num_compromised, root_shell, su_attempted, num_root, num_file_creations, num_shells, num_access_files, is_host_login, is_guest_login
G3 – Time	7: sjit, djit, sinpkt, dinpkt, tcprtt, synack, ackdat	9 (lưu lượng trong 2 giây gần nhất): count, srv_count, serror_rate, srv_serror_rate, rerror_rate, srv_rerror_rate, same_srv_rate, diff_srv_rate, srv_diff_host_rate
G4 – Additional (UNSW) / Host (NSL)	12: is_sm_ips_ports, ct_state_ttl, ct_flw_http_mthd, is_ftp_login, ct_ftp_cmd, ct_srv_src, ct_srv_dst, ct_dst_ltm, ct_src_ltm, ct_src_dport_ltm, ct_dst_sport_ltm, ct_dst_src_ltm	10 (100 kết nối gần nhất tới cùng máy đích): dst_host_count, dst_host_srv_count, dst_host_same_srv_rate, dst_host_diff_srv_rate, dst_host_same_src_port_rate, dst_host_srv_diff_host_rate, dst_host_serror_rate, dst_host_srv_serror_rate, dst_host_rerror_rate, dst_host_srv_rerror_rate

Ghi chú: trong bộ train/test của UNSW-NB15, nhóm luồng (Flow) chỉ còn proto nên được gộp vào Basic; rate không có trong mô tả gốc nên cũng xếp vào Basic; stcpb, dtcpb là số thứ tự TCP ban đầu (gần như ngẫu nhiên) nhưng vẫn giữ đúng nhóm gốc.

Các bước tiền xử lý:

- Đặc trưng số không âm được lấy $\log(1 + x)$. Mọi đặc trưng số được chuẩn hóa z-score theo thống kê của tập train, rồi cắt vào khoảng $[-10, 10]$.
- Đặc trưng phân loại được đổi sang số nguyên theo từ điển của tập train, thêm một mã “không biết” cho giá trị chỉ có ở tập test.
- Trọng số của mỗi lớp tỉ lệ với $1/\sqrt{(\text{tần suất lớp})}$, để giảm ảnh hưởng của mất cân bằng.
- Mọi lựa chọn (siêu tham số, dừng sớm) chỉ dựa trên macro-F1 của tập validation. Tập test chỉ dùng để báo cáo kết quả cuối.

Sau tiền xử lý, đầu vào của mô hình cho mỗi luồng là cặp $(x_{\text{num}}, x_{\text{cat}})$, với $x_{\text{num}} \in \mathbb{R}^{39}$ (UNSW-NB15) hoặc $\mathbb{R}^{37}$ (NSL-KDD) và x_{cat} gồm 3 số nguyên. Mỗi cột thuộc đúng một nhóm theo Bảng 4.

5.2. Dữ liệu đầu ra

Bảng 5: Các đầu ra của SFG-XIDS

Đầu ra	Dạng	Ý nghĩa
Nhân dự đoán $\hat{y}$	Một trong C lớp	Lớp có xác suất cao nhất
Xác suất $p(c x)$	Vector C phần tử, tổng bằng 1	Softmax của logit $z(x)$; bài toán nhị phân dùng xác suất Attack để tính ROC-AUC
Đóng góp nhóm $\phi(x)$	Vector 4 phần tử (đơn vị logit)	Mỗi nhóm đẩy logit của lớp c lên hay xuống bao nhiêu so với mức trung bình của tập nền; tổng bằng $z_c(x) - E[z_c]$
Bản đồ tương tác $ g_{ij} $	Ma trận 4×4 (6 cặp)	Phản tương tác thực giữa hai nhóm, lấy trung bình theo lớp
Đóng góp đặc trưng $a(x)$	Vector 42 (UNSW) / 40 (NSL) phần tử	Tính bằng EG trong từng nhóm; tổng mỗi nhóm bằng $\phi_i(x)$
Hồ sơ theo lớp	Bảng $C \times 4$ và danh sách đặc trưng đứng đầu	Tỉ lệ trung bình $ \phi_i $ của mỗi nhóm và đặc trưng quan trọng nhất trong nhóm, cho từng lớp

Ví dụ đầu ra. Bảng 6 là lời giải thích thật cho lớp R2L của một kết nối R2L trong KDDTest+ (mô hình seed 0). Tổng đóng góp của 4 nhóm là 8,08 đơn vị logit. Nhóm Content đóng góp nhiều nhất, và cấp đặc trưng cho thấy đặc trưng chính là is_guest_login (đăng nhập bằng tài khoản khách – dấu hiệu hay gặp ở các tấn công R2L qua FTP như warezmaster).

Bảng 6: Ví dụ lời giải thích 2 cấp cho một kết nối R2L (NSL-KDD)

Nhóm	ϕ_i (cấp nhóm)	Tổng EG (cấp đặc trưng)	Các đặc trưng đóng góp nhiều nhất (EG)
Basic	1,954	1,935	service 1,032; src_bytes 0,677; flag 0,429
Content	4,251	4,292	is_guest_login 2,211; logged_in 0,784; hot 0,652
Time	1,284	1,297	srv_count 0,555; count 0,399
Host	0,586	0,579	dst_host_serror_rate -0,614; dst_host_same_srv_rate 0,548; dst_host_srv_count 0,492
Tổng	8,075	8,103	Chênh lệch nhỏ là sai số tính tích phân (mục 6.6)


5.3. Cách đánh giá

- **Phát hiện:** macro-F1 (chỉ số chính, vì dữ liệu mất cân bằng) và Accuracy. Bài toán nhị phân thêm DR (tỉ lệ phát hiện, tức recall của lớp Attack), FAR = FP/(FP + TN) (tỉ lệ báo động nhầm), F1 của lớp Attack và ROC-AUC.
- **Giải thích,** theo 5 tiêu chí:

- (1) **Đúng**: so đóng góp nhóm tính bằng công thức với giá trị Shapley tính theo định nghĩa (duyet hết mọi tổ hợp nhóm).
- (2) **Khớp 2 cấp**: $|\sum_{k \in G_i} EG_k - \varphi_i|$ chia cho $\sum_i |\varphi_i|$.
- (3) **Trung thực**: xóa nhóm hoặc đặc trưng được xếp quan trọng nhất rồi xem xác suất giảm bao nhiêu. Giảm càng nhiều thì lời giải thích càng đúng với mô hình.
- (4) **Ổn định**: so thứ hạng nhóm giữa 5 seed bằng Kendall τ và tỉ lệ lớp giữ nguyên nhóm hạng 1.
- (5) **Hợp lý**: kiểm tra 2 giả thuyết đặt ra trước, dựa trên thiết kế của NSL-KDD.
- **Cách báo cáo**: trung bình $\pm$ độ lệch chuẩn qua 5 seed. Khi so hai mô hình, lấy chênh lệch theo từng seed rồi tính trung bình $\pm$ độ lệch chuẩn.

6. Methodology đề xuất

6.1. Tổng quan



Hình 1: Kiến trúc SFG-XIDS: 4 encoder độc lập cho 4 nhóm, lớp output cộng theo nhóm GAI-Head và cách giải thích 2 cấp

SFG-XIDS gồm 5 khối (Hình 1): (1) tiền xử lý và chia 4 nhóm theo cách chia gốc của bộ dữ liệu; (2) 4 encoder, mỗi nhóm một encoder, độc lập với nhau; (3) lớp output cộng theo nhóm GAI-Head; (4) train với group dropout; (5) giải thích 2 cấp. Điểm quan trọng nhất: thông tin của các nhóm chỉ gặp nhau ở GAI-Head, qua các thành phần được viết ra rõ ràng.

6.2. Encoder cho từng nhóm

Mỗi đặc trưng số x_k được biến thành một vector 16 chiều bằng embedding PLR [10] (Periodic $\rightarrow$ Linear $\rightarrow$ ReLU):

$$t_k = \text{ReLU}(W_k [\sin(2\pi c_k x_k); \cos(2\pi c_k x_k)] + b_k) \in \mathbb{R}^{16}$$

Trong đó c_k là 32 tần số được học, khởi tạo ngẫu nhiên từ phân phối chuẩn $N(0, \sigma^2)$. Nói đơn giản: thay vì đưa một con số thô vào mạng, ta biểu diễn nó bằng nhiều sóng sin/cos, giúp mạng học được các quan hệ phức tạp (nhiều ngưỡng, nhiều khúc) của từng đặc trưng. Đặc trưng phân loại dùng bảng embedding 16 chiều.

Embedding của các đặc trưng trong nhóm i được nối lại thành vector s_i , rồi đi qua một MLP có kết nối tắt (residual):

$$h_i = \text{LeakyReLU}(W_i^{(1)} s_i + b_i^{(1)})$$

$$e_i = \text{LayerNorm}(h_i + \text{LeakyReLU}(W_i^{(2)} h_i + b_i^{(2)})) \in \mathbb{R}^{64}$$

Vector e_i chỉ phụ thuộc vào x_i : trước GAI-Head, không có thông tin nào đi từ nhóm này sang nhóm khác.

6.3. Lớp output GAI-Head

$$z_c(x) = b_c + \sum_{i=1..4} u_{i,c}(e_i) + \sum_{1 \leq i < j \leq 4} v_{ij,c}(e_i, e_j)$$

Đọc công thức như sau: logit của lớp c = hằng số + phần riêng của từng nhóm + phần tương tác của từng cặp nhóm. Phần riêng u_i là một lớp tuyến tính. Phần tương tác v_{ij} là một MLP 2 lớp (64 nơ-ron ẩn, LeakyReLU) với đầu vào $[e_i; e_j; e_i \odot e_j]$. Có 4 phần riêng và 6 phần cặp.

Bên trong một nhóm, các đặc trưng tương tác với nhau tùy ý (qua encoder). Giữa các nhóm, tương tác chỉ có theo từng cặp và được viết ra rõ ràng. Khác với GA²M hay NAM (cộng theo từng đặc trưng), SFG-XIDS cộng theo nhóm – đúng mức mà chuyên viên cần đọc.

6.4. Train và group dropout

Hàm mất mát là cross-entropy có trọng số lớp, tối ưu bằng AdamW (learning rate 10^{-3} , batch 1024, tối đa 60 epoch, dừng sớm khi macro-F1 validation không tăng sau 6 epoch).

Group dropout: khi train, với xác suất p , mỗi nhóm của mỗi mẫu bị thay bằng đúng nhóm đó lấy từ một mẫu khác trong cùng batch. Dùng hoán đổi thay vì gán 0 để giữ nguyên phân phối thật của nhóm. Mục đích: buộc mỗi nhóm phải tự mang thông tin, và hạn chế

việc mô hình đồn đóng góp một cách tùy tiện vào một nhóm trong khi nhóm khác chứa thông tin tương tự.

6.5. Giải thích cấp nhóm: đóng góp chính xác của từng nhóm

Gọi B là tập nền gồm 256 luồng lấy từ tập train. Khi tính giá trị trung bình, giá trị của mỗi nhóm được lấy từ các luồng trong B , các nhóm được xét độc lập với nhau, và trung bình được tính trên toàn bộ B (không lấy mẫu ngẫu nhiên). Ký hiệu có dấu phẩy, ví dụ e'_j , là giá trị lấy từ tập nền.

Bước 1 – tách mỗi thành phần cặp v_{ij} [18] thành: giá trị trung bình, hai phần mà mỗi phần chỉ phụ thuộc một nhóm, và phần tương tác thực của cặp:

$$\bar{v}_{ij} = E[v_{ij}(e'_i, e'_j)], \quad m_{i \leftarrow j}(e_i) = E_{e'_j}[v_{ij}(e_i, e'_j)] - \bar{v}_{ij}$$

$$g_{ij}(e_i, e_j) = v_{ij}(e_i, e_j) - m_{i \leftarrow j}(e_i) - m_{j \leftarrow i}(e_j) - \bar{v}_{ij}$$

Ý nghĩa: $m_{i \leftarrow j}$ là phần của v_{ij} chỉ phụ thuộc vào nhóm i (đã lấy trung bình theo nhóm j); g_{ij} là phần còn lại, chỉ xuất hiện khi cả hai nhóm cùng có mặt.

Bước 2 – đóng góp của nhóm i cho logit của lớp c :

$$\varphi_i(x) = [u_i(e_i) - E u_i(e'_i)] + \sum_{j \neq i} m_{i \leftarrow j}(e_i) + \frac{1}{2} \sum_{j \neq i} g_{ij}(e_i, e_j)$$

Tức là: phần riêng của nhóm i + các phần của thành phần cặp chỉ phụ thuộc nhóm i + một nửa phần tương tác thực với mỗi nhóm khác.

Tính chất 1 (hệ quả của [12, 2], áp dụng cho nhóm). Xét cách tính giá trị Shapley trong đó nhóm nào “vắng mặt” thì được thay bằng các giá trị của nhóm đó trong tập nền B rồi lấy trung bình, và các nhóm được thay độc lập với nhau. Khi đó: (a) $\sum_i \varphi_i(x) = z_c(x) - E[z_c]$; (b) $\varphi_i(x)$ đúng bằng giá trị Shapley của nhóm i .

Vì sao đúng (ngắn gọn). Logit tách được thành một hằng số, các phần chỉ phụ thuộc một nhóm và các phần tương tác thực g_{ij} (trung bình của g_{ij} theo từng nhóm đều bằng 0). Giá trị Shapley cộng được theo từng thành phần, nên có thể xét riêng từng phần. Phần chỉ phụ thuộc nhóm i thì thuộc hết về nhóm i . Phần g_{ij} chỉ xuất hiện khi cả i và j cùng có mặt, nên theo tính đối xứng của giá trị Shapley, mỗi nhóm nhận một nửa. Cộng lại ra đúng công thức của φ_i ; (a) đúng vì giá trị Shapley luôn có tổng bằng phần chênh lệch cần giải thích.

Bản đồ tương tác $M_c[i, j]$ là trung bình $|g_{ij}|$ trên các luồng thuộc lớp c , báo cáo dưới dạng tỉ lệ so với $\sum_i E|\varphi_i|$. Chi phí: với mỗi luồng và mỗi cặp nhóm, chỉ cần $O(|B|)$ lần tính MLP cặp, thay vì phải duyệt 2^4 tổ hợp nhóm nhân với mọi tổ hợp giá trị nền của các nhóm vắng mặt.

6.6. Giải thích cấp đặc trưng: đóng góp của từng đặc trưng trong nhóm

Giữ các nhóm khác cố định tại x , φ_i chỉ còn là hàm của embedding $t_i = (t_k)_{k \in G_i}$ của các đặc trưng trong nhóm i . Đóng góp của đặc trưng $k \in G_i$ được tính bằng Expected Gradients [8], với các điểm tham chiếu lấy từ chính tập nền B :

$$EG_k(x) = \frac{1}{|B|} \sum_{b \in B} \int_0^1 (t_k - t_k^{(b)})^\top \frac{\partial \varphi_i(t_i^{(b)} + \alpha(t_i - t_i^{(b)}))}{\partial t_k} d\alpha$$

Nói đơn giản: với mỗi điểm tham chiếu b , ta đi theo đường thẳng từ b tới x , cộng dồn gradient dọc đường (nhân với độ chênh $t_k - t_k^{(b)}$), rồi lấy trung bình trên 256 điểm tham chiếu.

Tính chất 2. Với mọi luồng x và mọi nhóm i :

$$\sum_{k \in G_i} EG_k(x) = \varphi_i(x)$$

Vì sao đúng (ngắn gọn). Với mỗi điểm tham chiếu b , cộng tích phân gradient dọc đường thẳng cho ra đúng $\varphi_i(t_i) - \varphi_i(t_i^{(b)})$ (định lý cơ bản của giải tích). Lấy trung bình trên B , phần $\varphi_i(t_i^{(b)})$ có trung bình bằng 0 một cách chính xác, vì cả 3 phần của φ_i đều đã được trừ trung bình trên B ở bước tách thành phần (mục 6.5).

Như vậy, các con số cộng khớp qua 3 mức: đặc trưng $\rightarrow$ nhóm $\rightarrow$ logit. Đường tích phân đi trong không gian embedding (với đặc trưng phân loại, đóng góp là tổng theo các chiều embedding), vì PLR có thành phần sin/cos tần số cao ($\sigma = 10$ trên UNSW-NB15) khiến tích phân theo giá trị thô dao động mạnh. Tích phân theo α được tính gần đúng bằng 16 điểm Gauss–Legendre. Do LeakyReLU có điểm gãy, vẫn còn một sai số tính tích phân nhỏ, và sai số này giảm khi tăng số điểm (trong kiểm thử trên dữ liệu tổng hợp với hàm kích hoạt tron, sai số chỉ còn khoảng 10^{-15}).

Đối chứng “EG phẳng”. Để trả lời câu hỏi “sao không chạy EG trên toàn mô hình rồi cộng theo nhóm?”, đề tài tính thêm EG thông thường trên toàn logit (một đường tích phân chung cho mọi đặc trưng, cùng tập nền với các nhóm lấy độc lập), cộng theo nhóm rồi so với φ .

6.7. Các biến thể dùng để so sánh

- **SFG-Concat:** cùng 4 encoder, nhưng nối 4 vector e_i lại rồi đưa qua MLP (không cộng theo nhóm).

- **SFG-Attn:** 4 encoder + self-attention giữa các nhóm + pooling có trọng số γ – kiến trúc nhiều nhánh điển hình. Dùng để kiểm tra xem trọng số attention có dùng làm lời giải thích được không.

7. Cài đặt giải pháp


7.1. Code

Bảng 7: Các file mã nguồn

File	Vai trò
step0_sfg.py	Thư viện lõi: đọc và tiền xử lý dữ liệu, chia nhóm, các mô hình (Flat-MLP, SFG-Attn, SFG-XIDS), vòng lặp train, group dropout, công thức tính đóng góp nhóm và giá trị Shapley tính theo định nghĩa
step0_unsw.py	Đọc file UNSW-NB15 và kiểm tra bộ chia chính thức (số dòng, tên lớp)
full_sfg.py	Thí nghiệm chính: chọn σ và p ; 7 mô hình $\times$ 5 seed (nhiều lớp); ablation A1–A6; giải thích cấp nhóm cho SFG-XIDS, SFG-Attn, XGBoost; độ ổn định; kiểm tra giả thuyết H1/H2; kiểm tra trọng số attention
phase2_sfg.py	Giải thích cấp đặc trưng (EG trong nhóm, EG phẳng, thí nghiệm xóa đặc trưng, TreeSHAP); bài toán nhị phân (6 mô hình); FT-Transformer

Mỗi script có chế độ tự kiểm tra trên dữ liệu tổng hợp (--selftest) và chế độ chạy nhanh (--quick). Kết quả được ghi vào results.json sau mỗi lần chạy, nên khi Colab ngắt phiên có thể chạy tiếp từ chỗ đã dừng.

7.2. Luồng xử lý của chương trình



Hình 2: Sơ đồ luồng xử lý của chương trình

Sau khi đọc dữ liệu, tiền xử lý và tạo nhóm, σ của PLR được chọn bằng Flat-MLP và p của group dropout được chọn bằng SFG-XIDS; cả hai chỉ dựa trên tập validation với seed 0. Sau đó chương trình chạy lần lượt mọi cấu hình (mô hình $\times$ seed); cấu hình nào đã có kết quả thì bỏ qua. Với các mô hình cần giải thích, phần giải thích cấp nhóm được tính ngay sau khi train và trọng số mô hình được lưu lại; phần giải thích cấp đặc trưng chạy trên chính

các mô hình đã lưu. Cuối cùng, chương trình tổng hợp trung bình, độ lệch chuẩn và chênh lệch theo từng seed (Hình 2).

7.3. Thuật toán giải thích

Thuật toán 1 – Đóng góp nhóm (cấp nhóm). TB là viết tắt của “trung bình”.

Đầu vào: mô hình SFG-XIDS, tập nền B, luồng x, lớp c

1. $e_i \leftarrow \text{Enc}_i(x_i)$; $e'_i(b) \leftarrow \text{Enc}_i(x_i^{\wedge}(b))$ với mọi $b \in B$, $i = 1..4$

2. $\bar{u}_i \leftarrow \text{TB}_b u_i(e'_i(b))$; $\bar{v}_{ij} \leftarrow \text{TB}_b v_{ij}(e'_i(b), e'_j(b))$

3. Với mỗi cặp (i, j) :

$A_i \leftarrow \text{TB}_b v_{ij}(e_i, e'_j(b))$; $A_j \leftarrow \text{TB}_b v_{ij}(e'_i(b), e_j)$

$g_{ij} \leftarrow v_{ij}(e_i, e_j) - A_i - A_j + \bar{v}_{ij}$

$\phi_i \leftarrow (A_i - \bar{v}_{ij}) + \frac{1}{2} g_{ij}$; $\phi_j \leftarrow (A_j - \bar{v}_{ij}) + \frac{1}{2} g_{ij}$

4. $\phi_i \leftarrow u_i(e_i) - \bar{u}_i$; lấy phần của lớp c (logit đã trừ TB các lớp)

Đầu ra: $\phi \in \mathbb{R}^4$ và 6 phần tương tác g_{ij}

Thuật toán 2 – Expected Gradients trong nhóm (cấp đặc trưng).

Đầu vào: như trên; m điểm Gauss-Legendre $\alpha_1..\alpha_m$ với trọng số $w_1..w_m$

1. Với mỗi nhóm i: $t_i \leftarrow \text{embedding}$ các đặc trưng của x trong G_i ; $t_i^{\wedge}(b)$ với mọi $b \in B$

2. Với mỗi $b \in B$ và mỗi điểm α_r : $p \leftarrow t_i^{\wedge}(b) + \alpha_r (t_i - t_i^{\wedge}(b))$

3. $h(p) \leftarrow u_i(\text{MLP}_i(p)) + \frac{1}{2} \sum_{(j \neq i)} [v_{ij}(\text{MLP}_i(p), e_j) + \text{TB}_b v_{ij}(\text{MLP}_i(p), e'_j(b))]$

4. tính $\nabla h(p)$ bằng autograd

5. $\text{EG}_k \leftarrow (1/|B|) \sum_b \sum_r w_r (t_k - t_k^{\wedge}(b)) \cdot \partial h / \partial t_k$, $k \in G_i$

Đầu ra: $a \in \mathbb{R}^d$, với $\sum_{(k \in G_i)} a_k = \phi_i$ (sai lệch chỉ do tính tích phân gần đúng)

MLP_i là phần MLP của encoder nhóm i (mục 6.2), nhận embedding các đặc trưng của nhóm. Hàm h là phần của ϕ_i phụ thuộc vào nhóm i; các phần còn lại không đổi khi chỉ nhóm i thay đổi nên không ảnh hưởng gradient. Bước 3 được tính theo lô trên GPU cho mọi điểm nền và mọi điểm tích phân cùng lúc.

7.4. Siêu tham số và quy trình thí nghiệm

Bảng 8: Siêu tham số và thiết lập thí nghiệm

Thành phần	Thiết lập
Chia dữ liệu	Train/test chính thức; validation 10% giữ tỉ lệ lớp; 5 seed (0–4)
XGBoost	hist, độ sâu 8, learning rate 0,1, subsample/colsample 0,8, tối đa 2000 cây, dừng sớm sau 50 vòng, xử lý trực tiếp đặc trưng phân loại; nhị phân: binary:logistic

LightGBM	63 lá, learning rate 0,05, subsample/colsample 0,8, dừng sớm sau 50 vòng
Random Forest	300 cây
Flat-MLP	256-256-128, BatchNorm, dropout 0,1, đầu vào PLR
FT-Transformer	Cấu hình mặc định của [9]: token 192 chiều, 3 khối, 8 đầu attention; AdamW lr 10^{-4} , batch 512, patience 10
SFG-XIDS	Embedding 16 chiều (PLR 32 tần số), encoder 64 chiều, MLP cặp 64 nơ-ron; AdamW lr 10^{-3} , batch 1024, tối đa 60 epoch, patience 6
σ của PLR	Chọn trong $\{0,3; 1; 3; 10\}$ bằng Flat-MLP: 10 (UNSW-NB15), 1 (NSL-KDD); dùng chung cho các mạng dùng embedding PLR (Flat-MLP, SFG-Concat, SFG-Attn, SFG-XIDS)
p của group dropout	Chọn trong $\{0,1; 0,2; 0,3\}$ bằng SFG-XIDS: 0,3 (UNSW-NB15), 0,1 (NSL-KDD)
Giải thích	Tập nền 256 luồng train; cấp nhóm: tối đa 400 luồng test mỗi lớp; cấp đặc trưng: tối đa 100 luồng mỗi lớp, 16 điểm tích phân; mô hình hộp đen: Shapley nhóm ước lượng Monte Carlo với 128 tổ hợp nền

7.5. Chi phí tính toán

Bảng 9: Chi phí tính toán đo thực tế trên một GPU T4

Hạng mục	UNSW-NB15	NSL-KDD
Số tham số SFG-XIDS	185 nghìn	177 nghìn
Số tham số Flat-MLP / FT-Transformer	318 nghìn / 939 nghìn	306 nghìn / 924 nghìn
Một lần chạy SFG-XIDS (train và các bước giải thích)	≈ 46 giây	≈ 22 giây
Một lần chạy XGBoost (kể cả giải thích Monte Carlo) / train FT-Transformer	≈ 25 giây / $\approx 6,2$ phút	≈ 13 giây / $\approx 3,2$ phút
Giải thích cấp nhóm (ϕ + bản đồ tương tác), mỗi luồng	0,3 ms	0,2 ms
Giải thích cấp đặc trưng (cả 4 nhóm), mỗi luồng	0,22 giây	0,22 giây
EG phẳng / TreeSHAP của XGBoost, mỗi luồng	4,6 ms / 6,6 ms	4,5 ms / 4,2 ms

8. Kết quả thực nghiệm

8.1. Phát hiện nhiều lớp

Bảng 10: Phát hiện nhiều lớp trên tập test chính thức (% , trung bình $\pm$ độ lệch chuẩn qua 5 seed). Δ : chênh lệch macro-F1 so với SFG-XIDS, tính theo từng seed (mô hình đó – SFG-XIDS)

Mô hình	UNSW macro-F1	UNSW Acc.	UNSW Δ	NSL macro-F1	NSL Acc.	NSL Δ
XGBoost	51,43 $\pm$ 0,29	70,55 $\pm$ 0,10	-0,92 $\pm$ 1,69	57,79 $\pm$ 0,97	78,83 $\pm$ 0,19	-5,08 $\pm$ 1,45
LightGBM	52,68 $\pm$ 0,29	72,37 $\pm$ 0,05	+0,33 $\pm$ 1,35	54,23 $\pm$ 0,71	75,52 $\pm$ 0,20	-8,65 $\pm$ 1,97
Random Forest	48,50 $\pm$ 0,33	75,23 $\pm$ 0,05	-3,86 $\pm$ 1,68	47,86 $\pm$ 0,41	74,18 $\pm$ 0,32	-15,01 $\pm$ 1,65
Flat-MLP	52,28 $\pm$ 0,55	73,34 $\pm$ 0,17	-0,08 $\pm$ 1,90	58,76 $\pm$ 2,21	76,38 $\pm$ 0,37	-4,12 $\pm$ 2,98
FT-Transformer	48,86 $\pm$ 0,52	71,63 $\pm$ 1,11	-3,49 $\pm$ 1,78	64,26 $\pm$ 3,15	79,53 $\pm$ 1,09	+1,38 $\pm$ 1,42
SFG-Concat	52,42 $\pm$ 0,80	72,78 $\pm$ 0,74	+0,06 $\pm$ 2,02	55,98 $\pm$ 2,70	76,24 $\pm$ 1,42	-6,90 $\pm$ 3,84
SFG-Attn	52,16 $\pm$ 0,70	73,15 $\pm$ 0,72	-0,20 $\pm$ 1,81	59,63 $\pm$ 3,63	76,49 $\pm$ 1,36	-3,25 $\pm$ 3,55
SFG-XIDS	52,35 $\pm$ 1,51	72,61 $\pm$ 0,88	—	62,88 $\pm$ 1,89	77,47 $\pm$ 1,32	—

Trên UNSW-NB15, khoảng cách giữa SFG-XIDS (52,35) và LightGBM, XGBoost, Flat-MLP, SFG-Concat, SFG-Attn đều nhỏ hơn độ lệch chuẩn của chênh lệch, tức là nằm trong mức dao động giữa các seed. Chỉ Random Forest (-3,86 $\pm$ 1,68) và FT-Transformer (-3,49 $\pm$ 1,78) thấp hơn rõ. Macro-F1 chỉ quanh 52% chủ yếu do một số lớp có F1 thấp: với SFG-XIDS, F1 là 0,5 ở Analysis, 8,4 ở Backdoor và khoảng 40 ở DoS, Fuzzers, Shellcode. Trên NSL-KDD, FT-Transformer (64,26) và SFG-XIDS (62,88) tốt nhất; chênh lệch +1,38 $\pm$ 1,42 nằm trong mức dao động giữa các seed; các mô hình cây kém hơn rõ.

8.2. Phát hiện nhị phân

Bảng 11: Phát hiện nhị phân Attack/Normal (% , trung bình $\pm$ độ lệch chuẩn qua 5 seed); DR và F1 tính cho lớp Attack

Mô hình	Accuracy	DR	FAR	F1	Macro-F1	ROC-AUC
UNSW-NB15						
XGBoost	88,05 $\pm$ 0,10	97,46 $\pm$ 0,10	23,48 $\pm$ 0,17	89,98 $\pm$ 0,08	87,59 $\pm$ 0,10	98,23 $\pm$ 0,04
LightGBM	88,21 $\pm$ 0,17	97,75 $\pm$ 0,11	23,47 $\pm$ 0,27	90,13 $\pm$ 0,14	87,75 $\pm$ 0,18	98,32 $\pm$ 0,05
Random Forest	87,10 $\pm$ 0,03	98,71 $\pm$ 0,02	27,12 $\pm$ 0,07	89,39 $\pm$ 0,02	86,47 $\pm$ 0,03	97,94 $\pm$ 0,02
Flat-MLP	87,71 $\pm$ 0,55	96,85 $\pm$ 0,24	23,50 $\pm$ 1,11	89,67 $\pm$ 0,43	87,25 $\pm$ 0,59	97,52 $\pm$ 0,31
FT-Transformer	88,95 $\pm$ 0,54	96,96 $\pm$ 0,63	20,87 $\pm$ 1,37	90,62 $\pm$ 0,42	88,58 $\pm$ 0,58	98,09 $\pm$ 0,30

SFG-XIDS	88,15 ± 0,80	97,64 ± 0,63	23,47 ± 2,28	90,08 ± 0,57	87,69 ± 0,89	98,22 ± 0,17
NSL-KDD						
XGBoost	81,17 ± 0,25	69,16 ± 0,53	2,96 ± 0,24	80,70 ± 0,32	81,16 ± 0,25	96,10 ± 0,21
LightGBM	78,83 ± 0,14	64,93 ± 0,25	2,80 ± 0,02	77,74 ± 0,19	78,78 ± 0,15	96,48 ± 0,12
Random Forest	77,46 ± 0,27	62,55 ± 0,47	2,83 ± 0,04	75,96 ± 0,36	77,37 ± 0,28	96,62 ± 0,20
Flat-MLP	77,37 ± 1,26	63,08 ± 2,36	3,76 ± 1,99	76,02 ± 1,61	77,29 ± 1,29	90,01 ± 3,58
FT-Transformer	80,59 ± 1,45	69,66 ± 3,78	4,97 ± 2,58	80,29 ± 2,02	80,57 ± 1,47	95,55 ± 0,20
SFG-XIDS	79,00 ± 0,88	67,56 ± 2,03	5,90 ± 1,78	78,54 ± 1,13	78,98 ± 0,88	95,70 ± 0,50

Trên UNSW-NB15, mọi mô hình chênh nhau trong khoảng 2 điểm macro-F1 và đều có FAR 21–27% trên tập test chính thức. Trên NSL-KDD, XGBoost tốt nhất (macro-F1 81,16); SFG-XIDS (78,98) đứng trên LightGBM, Random Forest và Flat-MLP, nhưng có FAR cao nhất (5,90%).

8.3. Ablation

Bảng 12: Ablation: macro-F1 nhiều lớp thay đổi bao nhiêu so với SFG-XIDS đầy đủ (biến thể – đầy đủ, tính theo từng seed)

Biến thể	UNSW-NB15	NSL-KDD
A2: SFG-XIDS đầy đủ (macro-F1, không phải chênh lệch)	52,35 ± 1,51	62,88 ± 1,89
A1: chỉ giữ phần riêng của từng nhóm (bỏ v_{ij})	−0,90 ± 1,38	+0,78 ± 3,62
A3: không dùng group dropout	+0,08 ± 1,33	−5,30 ± 2,64
A4: chia nhóm ngẫu nhiên, cùng kích thước (5 cách chia)	−0,11 ± 1,39	+2,02 ± 2,24
A5: bỏ sttl, dttl, ct_state_ttl	−0,72 ± 1,86	—
A6: PLR bỏ phần sin/cos (chỉ còn Linear → ReLU)	−5,07 ± 2,66	+1,65 ± 3,26

Bỏ 3 đặc trưng TTL làm XGBoost giảm $1,44 \pm 0,59$ điểm (gấp đôi SFG-XIDS) và Flat-MLP giảm $0,72 \pm 0,74$ điểm (bằng SFG-XIDS).

8.4. Đóng góp của các nhóm theo từng lớp

Bảng 13: Tỷ lệ trung bình $|\varphi_i|$ của mỗi nhóm theo lớp thật (trung bình 5 seed; lớn nhất in đậm) và cặp nhóm có tương tác mạnh nhất (trung bình $|g_{ij}|$ so với $\sum_i E|\varphi_i|$)

Lớp	Basic	Content	Time	Additional / Host	Cặp mạnh nhất
-----	-------	---------	------	-------------------	---------------

<i>UNSW-NB15</i>					
Analysis	0,31	0,32	0,10	0,28	Basic × Content 4,8%
Backdoor	0,35	0,32	0,09	0,24	Basic × Content 4,0%
DoS	0,37	0,30	0,12	0,21	Content × Additional 6,8%
Exploits	0,33	0,30	0,16	0,22	Basic × Content 10,6%
Fuzzers	0,32	0,29	0,13	0,26	Basic × Content 9,3%
Generic	0,32	0,30	0,13	0,26	Basic × Content 4,6%
Normal	0,26	0,24	0,23	0,27	Basic × Content 12,3%
Reconnaissance	0,32	0,35	0,15	0,19	Content × Additional 9,9%
Shellcode	0,37	0,35	0,08	0,21	Basic × Content 12,2%
Worms	0,42	0,38	0,07	0,12	Basic × Content 16,8%
<i>NSL-KDD</i>					
DoS	0,25	0,11	0,35	0,29	Basic × Time 13,8%
Normal	0,30	0,22	0,22	0,25	Basic × Content 10,7%
Probe	0,30	0,08	0,29	0,33	Basic × Time 6,1%
R2L	0,18	0,33	0,27	0,23	Basic × Content 6,0%
U2R	0,38	0,36	0,12	0,14	Basic × Content 5,1%

Trên UNSW-NB15, Basic và Content cộng lại chiếm 61–81% tổng độ lớn đóng góp ở mọi lớp tấn công. Time đóng góp ít nhất ở các lớp gắn với nội dung gói tin (Worms 0,07; Shellcode 0,08). Lưu lượng bình thường có tỉ lệ giữa các nhóm cân bằng nhất. Phần tương tác của một cặp nhóm có thể lớn tới 16,8% so với tổng độ lớn đóng góp của các nhóm (Worms, Basic × Content).

Trên NSL-KDD, cả 2 giả thuyết đặt ra trước theo thiết kế của bộ đặc trưng [17] đều đúng. **H1:** tỉ lệ Content ở R2L/U2R (0,344) lớn hơn ở DoS/Probe (0,098). **H2:** ở DoS/Probe, tỉ lệ của nhóm lưu lượng Time + Host (0,626) lớn hơn Content (0,098). Cả hai đúng ở 5/5 seed, và cũng đúng với XGBoost, SFG-Attn và biến thể không dùng group dropout.

8.5. Kiểm tra lời giải thích cấp nhóm

Đúng. Trên 16 luồng test mỗi lần chạy, giá trị Shapley được tính theo định nghĩa với đủ 2^4 tổ hợp nhóm và mọi tổ hợp nền của một tập nền rút gọn 6 luồng. Đóng góp nhóm tính bằng công thức lệch giá trị Shapley này tối đa $1,9 \cdot 10^{-6}$; $\sum_i \varphi_i$ lệch $z_c - E[z_c]$ tối đa $3,8 \cdot 10^{-6}$

trên mọi lần chạy – chỉ là sai số làm tròn số thực. Ước lượng Monte Carlo với 128 tổ hợp nền lệch so với công thức một khoảng L1 trung bình giữa các hồ sơ là 0,019 (UNSW-NB15) và 0,029 (NSL-KDD).

Bảng 14: Trọng số của SFG-Attn so với giá trị Shapley nhóm của chính mô hình này

Chỉ số	UNSW-NB15	NSL-KDD
Nhóm hạng 1 theo attention A trùng nhóm hạng 1 theo Shapley	46%	48%
Nhóm hạng 1 theo trọng số pooling γ trùng nhóm hạng 1 theo Shapley	85%	57%
Kendall τ giữa thứ hạng theo A / theo γ và theo Shapley	0,29 / 0,55	0,49 / 0,55
Xác suất lớp dự đoán giảm bao nhiêu khi xóa nhóm hạng 1 theo Shapley	0,54	0,33
... khi xóa nhóm hạng 1 theo γ / theo A / xóa nhóm ngẫu nhiên	0,52 / 0,33 / 0,21	0,25 / 0,25 / 0,15

Bảng 15: Độ ổn định của đóng góp nhóm qua 5 seed: tỉ lệ lớp có nhóm hạng 1 giống nhau ở cả 5 seed, Kendall τ trung bình giữa các seed, độ lệch chuẩn (SD) trung bình của tỉ lệ nhóm

Cách giải thích	UNSW hạng 1	UNSW τ	UNSW SD	NSL hạng 1	NSL τ	NSL SD
SFG-XIDS, công thức trực tiếp	40%	0,85	0,018	40%	0,72	0,029
SFG-XIDS, Monte Carlo	30%	0,80	0,019	20%	0,71	0,029
SFG-XIDS không dùng group dropout	80%	0,86	0,037	80%	0,81	0,033
SFG-Attn, Monte Carlo	80%	0,71	0,061	0%	0,55	0,065
XGBoost, Monte Carlo	100%	0,89	0,016	100%	0,97	0,010

Với SFG-XIDS, ở mọi lớp luôn có một nhóm đứng hạng 1 ở đa số seed (từ 3/5 seed trở lên), nhưng nhóm hạng 1 giống nhau ở cả 5 seed chỉ ở 40% số lớp. Group dropout làm tỉ lệ các nhóm dao động giữa các seed giảm một nửa trên UNSW-NB15 (SD 0,018 so với 0,037), nhưng lại làm nhóm hạng 1 hay đổi chỗ hơn, vì nó làm Basic và Content gần bằng nhau (Bảng 13).

8.6. Kiểm tra lời giải thích cấp đặc trưng

Bảng 16: Kiểm tra lời giải thích cấp đặc trưng (tối đa 100 luồng mỗi lớp, 5 mô hình mỗi bộ dữ liệu). Sai số: $|\sum_{k \in G_i} EG_k - \phi_i| / \sum_i |\phi_i|$. Trung thực: xác suất lớp thật giảm bao nhiêu khi thay k đặc trưng đứng đầu bằng giá trị nền

Chỉ số	UNSW-NB15	NSL-KDD
Khớp giữa 2 cấp		
Sai số với 16 điểm tích phân: trung vị / phân vị 99	$1,1 \times 10^{-3} / 1,8 \times 10^{-2}$	$1,2 \times 10^{-3} / 9,7 \times 10^{-3}$
Sai số trung vị với 4 / 16 / 128 điểm (kiểm thử riêng, 20 luồng)	$7,3 \times 10^{-3} / 9,7 \times 10^{-4} / 7,7 \times 10^{-5}$	$9,5 \times 10^{-3} / 9,9 \times 10^{-4} / 1,0 \times 10^{-4}$
Nhóm hạng 1 khác ϕ : EG trong nhóm	$1,7 \pm 0,8\%$	$1,0 \pm 0,7\%$
Nhóm hạng 1 khác ϕ : EG phẳng	$14,8 \pm 3,3\%$	$8,6 \pm 5,1\%$
Khoảng cách L1 giữa tỉ lệ nhóm và ϕ : EG trong nhóm / EG phẳng	0,007 / 0,088	0,006 / 0,056
Trung thực (xóa $k = 1 / 3 / 5$ đặc trưng)		
EG trong nhóm	0,139 / 0,373 / 0,437	0,073 / 0,284 / 0,425
EG phẳng	0,139 / 0,373 / 0,436	0,073 / 0,285 / 0,425
Đặc trưng ngẫu nhiên	0,014 / 0,037 / 0,066	0,007 / 0,022 / 0,042
Ổn định giữa các seed (Kendall τ / Jaccard top-5)		
EG trong nhóm	0,70 / 0,62	0,82 / 0,56
EG phẳng	0,69 / 0,63	0,82 / 0,58
TreeSHAP của XGBoost	0,86 / 0,89	0,91 / 0,87

Với 16 điểm tích phân, sai số trung vị khoảng 0,1% tổng độ lớn đóng góp của các nhóm, và giảm gần 100 lần khi tăng từ 4 lên 128 điểm. 1–2% luồng có nhóm hạng 1 khác ϕ là những trường hợp hai nhóm gần bằng nhau, nên bị quyết định bởi sai số tính toán nhỏ này. Ngược lại, EG phẳng làm đổi nhóm quan trọng nhất ở 14,8% (UNSW-NB15) và 8,6% (NSL-KDD) số luồng, dù dùng cùng tập nền. Ở cấp đặc trưng thì hai cách cho thứ hạng gần như trùng nhau (Kendall τ 0,95 và 0,98) và trung thực như nhau: xóa 5 đặc trưng đứng đầu làm xác suất lớp thật giảm nhiều hơn 6–10 lần so với xóa 5 đặc trưng ngẫu nhiên.

8.7. Phân tích cấp đặc trưng

Bảng 17: Đặc trưng đứng đầu mỗi nhóm (tỉ lệ trong nhóm, trung bình 5 seed) cho một số lớp

Lớp	Basic	Content	Time	Additional / Host
NSL-KDD				
DoS	flag 0,49	logged_in 0,79	count 0,18	dst_host_rerror_rate 0,31
Probe	src_bytes 0,28	logged_in 0,96	diff_srv_rate 0,27	dst_host_diff_srv_rate 0,23
R2L	service 0,29	logged_in 0,42; num_failed_logins 0,24	srv_count 0,34	dst_host_srv_count 0,17
U2R	service 0,35	root_shell 0,35; logged_in 0,17	srv_count 0,34	dst_host_srv_count 0,24
UNSW-NB15				
Exploits	sttl 0,23	smean 0,32	ackdat 0,20	ct_state_ttl 0,39
Reconnaissance	sbytes 0,51	smean 0,66	sjit 0,27	ct_state_ttl 0,41
Worms	sbytes 0,35	smean 0,60	ackdat 0,15	ct_flw_http_mthd 0,32
Normal	sttl 0,20	smean 0,29	dinpkt 0,24	ct_state_ttl 0,48

Trên NSL-KDD, kết quả cấp đặc trưng khớp với bản chất của từng loại tấn công: đoán mật khẩu hiện ra qua num_failed_logins trong nhóm Content của R2L; leo thang quyền qua root_shell ở U2R; dò quét qua diff_srv_rate và dst_host_diff_srv_rate ở Probe; tấn công làm nghẽn dịch vụ (DoS) qua flag, count và dst_host_rerror_rate. Cấp đặc trưng cũng cho thấy cờ đăng nhập logged_in chiếm phần lớn đóng góp của nhóm Content ở DoS, Probe và Normal (79–96%).

Trên UNSW-NB15, nhóm Content chủ yếu tác động qua kích thước gói trung bình smean (đứng đầu nhóm ở 9/10 lớp), chứ không qua số thứ tự TCP gần như ngẫu nhiên stcpb, dtcpb. Nhóm Additional chủ yếu tác động qua ct_state_ttl (đứng đầu nhóm ở 8/10 lớp). Ba đặc trưng TTL chiếm 9–22% tổng độ lớn đóng góp của SFG-XIDS ở mỗi lớp (22% ở Normal), trong khi TreeSHAP cho thấy XGBoost dồn 40% độ lớn đóng góp của lớp Normal vào TTL nhưng chỉ 2–15% ở các lớp tấn công. Thứ hạng đặc trưng của hai mô hình giống nhau ở mức yếu trên UNSW-NB15 (Kendall τ 0,35) và vừa phải trên NSL-KDD (0,63).

9. Đánh giá kết quả thực nghiệm

9.1. Về khả năng phát hiện

Ràng buộc cộng theo nhóm không làm giảm độ chính xác so với các cách kết hợp nơ-ron không có ràng buộc (SFG-Concat, SFG-Attn), và cho kết quả ngang cây tăng cường trên UNSW-NB15. Trên NSL-KDD nhiều lớp, SFG-XIDS hơn mọi mô hình cây và chỉ đứng sau FT-Transformer trong phạm vi dao động giữa các seed. SFG-XIDS không vượt trội: ở bài toán nhị phân trên NSL-KDD, nó kém XGBoost 2,18 điểm macro-F1 và có FAR cao hơn. Kết luận đúng là: SFG-XIDS chính xác ngang các mô hình mạnh, chứ không tốt hơn.

9.2. Về độ chính xác và tính khớp của lời giải thích

Hai tính chất được xác nhận bằng số: cấp nhóm trùng giá trị Shapley tính theo định nghĩa đến mức sai số làm tròn ($1,9 \cdot 10^{-6}$); cấp đặc trưng có tổng khớp cấp nhóm với sai số trung vị 0,1%, và sai số này tiến về 0 khi tăng số điểm tích phân. Nghĩa là chuyên viên có thể đi từ logit xuống nhóm, rồi xuống đặc trưng, mà các con số luôn cộng khớp với nhau.

9.3. Về chất lượng lời giải thích so với các cách làm tắt

- **Không nên dùng trọng số attention làm lời giải thích.** Trọng số attention của SFG-Attn chỉ chọn đúng nhóm quan trọng nhất ở 46–48% số luồng, và xóa nhóm do attention chọn làm xác suất giảm ít hơn nhiều so với xóa nhóm do Shapley chọn (0,33 so với 0,54 trên UNSW-NB15).
- **Tính điểm từng đặc trưng trên toàn mô hình rồi cộng theo nhóm làm sai ở cấp nhóm.** EG phẳng đôi nhóm quan trọng nhất ở 9–15% số luồng, trong khi ở cấp đặc trưng nó gần như trùng EG trong nhóm. Tức là lỗi nằm ở bước cộng lên nhóm, đúng như lập luận ở mục 2.2.
- **Hợp lý.** Trên NSL-KDD, cả cấp nhóm (H1, H2 đúng ở 5/5 seed) lẫn cấp đặc trưng (num_failed_logins, root_shell, diff_srv_rate...) đều khớp với thiết kế bộ dữ liệu và bản chất của tấn công.
- **Một phát hiện về dữ liệu.** Hai mô hình chính xác như nhau (SFG-XIDS và XGBoost) lại dựa vào TTL rất khác nhau. Vậy lời giải thích mô tả một mô hình cụ thể, không mô tả dữ liệu.

9.4. Vai trò của từng thành phần

- Tương tác giữa các cặp nhóm không làm tăng độ chính xác (A1), nhưng cho bản đồ tương tác, với phần tương tác của một cặp lớn tới 17% so với tổng độ lớn đóng góp của các nhóm.

- Chia nhóm theo cách chia gốc của bộ dữ liệu không chính xác hơn chia ngẫu nhiên (A4). Giá trị của nó là lời giải thích đọc được và có “đáp án thiết kế” để kiểm tra.
- Group dropout có ích rõ trên NSL-KDD (+5,30 điểm) và làm tỉ lệ nhóm ít dao động hơn, nhưng làm nhóm hạng 1 hay đổi chỗ hơn.
- Phần sin/cos của PLR rất quan trọng trên UNSW-NB15 (+5,07 điểm).

9.5. So sánh với cách dùng XGBoost rồi tính Shapley nhóm sau khi train

Bảng 18: SFG-XIDS so với XGBoost + Shapley nhóm tính sau khi train

Tiêu chí	XGBoost + Shapley nhóm	SFG-XIDS
Macro-F1 UNSW-NB15 (10 lớp)	51,43	52,35
Macro-F1 NSL-KDD: 5 lớp / nhị phân	57,79 / 81,16	62,88 / 78,98
Đóng góp nhóm	Ước lượng Monte Carlo (128 tổ hợp nền)	Chính xác, công thức trực tiếp, 0,2–0,3 ms/luồng
Tương tác giữa các nhóm	Không có sẵn, phải ước lượng thêm	Bản đồ 4×4 là thành phần thật của mô hình
Nhóm và đặc trưng cộng khớp	Không đảm bảo	Có (Tính chất 2)
Ổn định giữa các seed	Cao (nhóm hạng 1 giữ nguyên ở 100% số lớp)	Thấp hơn (40% số lớp)

Hai phương án bổ sung cho nhau: XGBoost cho lời giải thích ổn định hơn; SFG-XIDS cho lời giải thích chính xác theo cấu trúc, có bản đồ tương tác và khớp giữa 2 cấp. Nên chọn theo yêu cầu khi triển khai.

9.6. Điểm yếu

- Lời giải thích của mạng nơ-ron thay đổi giữa các lần train nhiều hơn XGBoost, ở cả cấp nhóm lẫn cấp đặc trưng.
- FAR ở bài toán nhị phân trên NSL-KDD cao nhất trong các mô hình (5,90%).
- Giải thích cấp đặc trưng mất 0,22 giây/luồng: phù hợp khi chuyên viên cần xem chi tiết một cảnh báo, nhưng không phù hợp để chạy cho mọi luồng. Giải thích cấp nhóm (0,3 ms) đủ nhanh để đi kèm mọi cảnh báo.

10. Kết luận – đóng góp của nghiên cứu

SFG-XIDS đưa việc kết hợp các nhóm đặc trưng vào ngay cấu trúc mô hình, dưới dạng cộng. Nhờ đó, đóng góp của nhóm đúng bằng giá trị Shapley nhóm của mô hình, đóng góp của từng đặc trưng cộng khớp với đóng góp nhóm, và độ chính xác không kém các cách kết hợp nơ-ron khác trên UNSW-NB15 và NSL-KDD. Thực nghiệm cũng cho thấy hai cách làm tắt phổ biến – đọc trọng số attention và cộng điểm từng đặc trưng theo nhóm – báo sai mức quan trọng của nhóm ở một tỉ lệ đáng kể các luồng.

10.1. Đóng góp chính

- **Kiến trúc SFG-XIDS với GAI-Head:** mô hình IDS có logit tách chính xác thành phần của từng nhóm đặc trưng và từng cặp nhóm, độ chính xác ngang các mô hình mạnh (UNSW-NB15: 52,35 so với 52,68 của LightGBM; NSL-KDD: 62,88, cao hơn mọi mô hình cây).
- **Cách giải thích 2 cấp khớp nhau:** đóng góp nhóm tính bằng công thức trực tiếp, đúng bằng giá trị Shapley nhóm (hệ quả của [12, 2] khi áp dụng cho nhóm; lệch $1,9 \cdot 10^{-6}$ so với tính theo định nghĩa; 0,3 ms/luồng). Điểm mới là cách mở từng nhóm xuống đặc trưng bằng EG trên ϕ đã tách thành phần, để tổng khớp đúng đóng góp nhóm (Tính chất 2; sai số trung vị 0,1%), mà không phải duyệt các tổ hợp đặc trưng trong nhóm như khi tính chính xác giá trị Owen.
- **Bảng chứng thực nghiệm về hai cách làm tắt:** trọng số attention không dùng làm lời giải thích được ($\tau = 0,29$ trên UNSW-NB15); cộng EG thông thường theo nhóm làm đổi nhóm quan trọng nhất ở 9–15% số luồng.

10.2. Đóng góp phụ

- Chia nhóm theo cách chia gốc của bộ dữ liệu, có đối chứng với chia ngẫu nhiên: cho thấy cách chia nhóm không làm độ chính xác thay đổi rõ rệt; giá trị của nó nằm ở chỗ dễ diễn giải.
- Bộ tiêu chí kiểm tra lời giải thích ở cấp nhóm (đúng, khớp 2 cấp, trung thực, ổn định, hợp lý), dựa trên các tiêu chí của Warnecke và cộng sự [30], có giả thuyết đặt trước trên NSL-KDD.
- Bộ kết quả so sánh trên cùng một quy trình: 8 mô hình ở bài toán nhiều lớp và 6 mô hình ở bài toán nhị phân (gồm FT-Transformer), 5 seed, bộ chia chính thức.
- Đo cụ thể mức mô hình dựa vào 3 đặc trưng TTL (sttl, dttl, ct_state_ttl) của UNSW-NB15: TTL chiếm 9–22% độ lớn đóng góp của SFG-XIDS, còn XGBoost dồn 40% độ lớn đóng góp của lớp Normal vào TTL.
- Mã nguồn chạy lại được trên một GPU T4 miễn phí, có chế độ tự kiểm tra và chạy tiếp được khi bị ngắt.

11. Giới hạn của nghiên cứu và hướng phát triển

Bảng 19: Giới hạn và hướng phát triển

#	Giới hạn	Hướng phát triển
1	Lời giải thích kém ổn định giữa các seed (nhóm hạng 1 giữ nguyên ở cả 5 seed chỉ ở 40% số lớp; τ cấp đặc trưng 0,70 so với 0,86 của XGBoost)	Gộp kết quả giải thích qua nhiều seed (ensemble), thêm ràng buộc ổn định khi train, báo cáo nhóm hạng 1 theo đa số seed
2	Chỉ có 2 bộ dữ liệu; NSL-KDD đã cũ; trên UNSW-NB15 các mô hình dựa nhiều vào TTL (mục 8.7)	Mở rộng sang CIC-IDS2017 và các bộ NetFlow chuẩn hóa; đánh giá chéo giữa các bộ dữ liệu
3	Không vượt trội cây tăng cường; bài toán nhị phân trên NSL-KDD kém XGBoost (78,98 so với 81,16), FAR cao hơn	Cải tiến encoder, xử lý mất cân bằng lớp, chọn ngưỡng theo FAR mục tiêu
4	Tập nền lấy các nhóm độc lập với nhau nên có thể ghép ra tổ hợp không có thật (ví dụ nội dung TCP ghép với thông tin cơ bản của UDP)	Dùng giá trị Shapley nhóm có điều kiện (conditional) và so sánh hai cách
5	Tương tác giữa các nhóm chỉ đến bậc 2 và không làm tăng độ chính xác	Tương tác bậc cao có kiểm soát số lượng; chọn cặp tương tác dựa trên dữ liệu
6	Giải thích cấp đặc trưng mất 0,22 giây/luồng; sai số tích phân giảm chậm khi tăng số điểm; đóng góp được gán cho embedding của đặc trưng, chưa phải giá trị thô	Thu nhỏ tập nền, tích phân thích nghi, bộ giải thích học sẵn; tính đóng góp trực tiếp trên giá trị thô
7	Chưa so với TabNet, EBM, giá trị Owen; mô hình cây và FT-Transformer dùng cấu hình cố định, chưa tinh chỉnh	Bổ sung các đối chứng này và tinh chỉnh siêu tham số công bằng cho mọi mô hình
8	Chưa đánh giá với người dùng thật (chuyên viên SOC)	Nghiên cứu người dùng: thời gian xử lý cảnh báo, mức tin tưởng và độ đúng của quyết định khi có và không có lời giải thích 2 cấp